

# 1. MSE vs Cross-Entropy in Classification

## 問題：

In class, we discussed that MSE is often used for regression, while classification uses losses like Cross Entropy. Why?

Will we learn classification-specific loss functions? How does MSE perform regarding numerical stability?

## 回答與解釋：

### MSE 適合 Regression 的原因：

MSE 等價於假設資料符合 Gaussian noise 的最大似然估計，因此用於連續值預測非常合理。

### Cross-Entropy 適合 Classification 的原因：

分類問題中，標籤服從 Bernoulli 或 Categorical 分布，其最大似然等價於 Cross-Entropy。使用 logits + BCEWithLogitsLoss 時梯度更穩定、收斂更快。

### MSE 用在分類的問題：

搭配 sigmoid/softmax 時產生多一項飽和導數  $\sigma'(z)$ ，當  $z$  很大或很小時梯度趨近 0，學習變得極慢，且對錯誤分類不敏感，數值表現差於 CE。

### 之後會遇到的分類 Loss：

weighted CE、focal loss、hinge loss (SVM)，這些都會在進階 ML 或 DL 課程看到。

### 相關文獻：

<https://papers.nips.cc/paper/2016/hash/33f2d1c4fdf7d5a2b8b0bb2745078e1c-Abstract.html>

<https://arxiv.org/abs/1708.02002>

<https://arxiv.org/abs/1901.07884>

## 2. Sigmoid 與 Vanishing Gradient 問題

### 當初提問問題：

Why is the sigmoid activation prone to vanishing gradients? Is there any alternatives or solutions?

### 回答與解釋：

Sigmoid 容易造成梯度消失的原因：

Sigmoid 的導數  $\sigma'(z) = \sigma(z)(1-\sigma(z))$ 。在  $z \rightarrow \pm\infty$  時， $\sigma(z) \rightarrow 0$  or  $1$ ，因此導數趨近 0。深度網路使用鏈式法則會讓梯度逐層相乘，造成梯度快速衰減。

### 替代方法：

Activation：ReLU、Leaky ReLU、ELU、GELU、Swish (皆較不容易飽和)。

訓練技巧：BatchNorm、Residual connections、He/Xavier 初始化。

### 相關文獻：

<https://arxiv.org/abs/1502.01852>

<https://arxiv.org/abs/1603.00391>

[-https://arxiv.org/abs/1706.02515](https://arxiv.org/abs/1706.02515)

### 3. GDA 為何假設 Gaussian？若資料不是 Gaussian 有何後果？如何改善？

#### 當時提問問題：

Why can each category be assumed to be Gaussian? If not Gaussian, what happens? How to improve?

#### 回答與解釋：

##### 假設 Gaussian 的原因：

1. 數學 tractable：高斯分布的對數似然、MLE、邊際分布都有 closed form。
2. 參數少、樣本效率高。
3. 在許多自然資料裡，特徵常由多個因素累積，近似 Gaussian ( CLT )。

##### 若資料不是 Gaussian 的後果：

1. Decision boundary 錯誤 ( 誤設模型 )
2. 機率校準差。
3. 類別呈多峰分布時，LDA/QDA 會表現不佳。

##### 改進方式：

1. 使用 **Gaussian Mixture Models** ( 多峰 )。
2. 放鬆協方差矩陣 ( QDA )。
3. 非參數密度估計。
4. 改用 logistic regression 或 neural nets 等 discriminative 模型。

## 相關文獻：

- <https://www.cs.cmu.edu/~tom/mlbook.html>
- <https://arxiv.org/abs/1805.07451>
- <https://www.stat.cmu.edu/~larry/all-of-statistics/>

## 4. 為何 MLE 難用於非正規化模型？Score Matching 為何可行？

### 當時提問問題：

Why is MLE hard for unnormalized models while score matching works?

### 回答與解釋：

#### 非正規化模型的問題：

1.  $p(x) = \tilde{p}(x) / Z(\theta)$ ，其中  $Z(\theta) = \int \tilde{p}(x) dx$  通常不可積分。
2. MLE 必須計算  $\partial \log Z / \partial \theta$ ，其中包含對模型分布的期望，是 computationally intractable。

#### Score Matching 的突破：

使用  $s_{\theta}(x) = \nabla_x \log p_{\theta}(x)$ ，其中  $\nabla_x \log p_{\theta}(x) = \nabla_x \log \tilde{p}_{\theta}(x) - \nabla_x \log Z(\theta)$ ，因為  $Z(\theta)$  與  $x$  無關  $\rightarrow \nabla_x \log Z(\theta) = 0$ ，因此 score matching 完全不用  $Z(\theta)$ 。因此能訓練 energy-based models 或 diffusion models 中的 score network。

## 相關文獻：

Hyvärinen (2005) Score Matching:

<https://www.cs.helsinki.fi/u/ahyvarin/papers/NCR-Hyvarinen2005.pdf>

<https://arxiv.org/abs/1907.05600>

<https://arxiv.org/abs/2011.13456>

## 5. Noise-scale Weight $\lambda(\sigma)$ 如何設計？其效果是什麼？

### 當初提問問題：

How should  $\lambda(\sigma)$  be designed in noise-conditioned score matching?

What are the impacts?

### 回答與解釋：

#### 為什麼需要 $\lambda(\sigma)$ ：

Score 在噪聲  $\sigma$  下大小約為  $O(1/\sigma)$ ，若不加權，某些噪聲層級的 loss 會壓過其他層級。 $\lambda(\sigma)$  能平衡不同  $\sigma$  的貢獻。

#### 常見 $\lambda(\sigma)$ 設計：

1.  $\lambda(\sigma) \propto \sigma^2$  ( NCSN 中最常見，能平衡 loss 尺度 ) 。
2.  $\lambda(\sigma) = \text{常數}$  ( 訓練較穩定但細節較差 ) 。
3.  $\lambda(\sigma) \propto 1/\sigma^2$  ( 強化細節，但訓練不穩 ) 。

#### 影響：

1. 偏向大  $\sigma \rightarrow$  global structure 好但細節差。
2. 偏向小  $\sigma \rightarrow$  細節好但取樣不穩。

3.  $\sigma^2 \rightarrow$  在穩定與細節間取得最佳平衡。

### 相關文獻：

- <https://arxiv.org/abs/1907.05600>
- <https://arxiv.org/abs/2011.13456>
- <https://arxiv.org/abs/2011.13456>